## Linguaggi e Computabilità

UniShare

Davide Cozzi @dlcgold

Gabriele De Rosa @derogab

Federica Di Lauro @f\_dila

# Indice

1	$\mathbf{Intr}$	$\operatorname{oduzione}$															2
	1.1	Definizioni	 														2

## Capitolo 1

### Introduzione

Questi appunti sono presi a lezione. Per quanto sia stata fatta una revisione è altamente probabile (praticamente certo) che possano contenere errori, sia di stampa che di vero e proprio contenuto. Per eventuali proposte di correzione effettuare una pull request. Link: https://github.com/dlcgold/Appunti.

Grazie mille e buono studio!

### 1.1 Definizioni

- un linguaggio è un insieme di stringhe che può essere generato mediante un dato meccanismo con delle date caratteristiche; un linguaggio può essere riconosciuto, ovvero dando in input una stringa un meccanismo può dirmi se appartiene o meno ad un linguaggio. I meccanismi che generano linguaggi si chiamano grammatiche, quelli che li riconoscono automi. I linguaggi formali fanno parte dell'informatica teorica (TCS)
- si definisce alfabeto come un insieme finito e non vuoto di simbolo (come per esempio il nostro alfabeto o le cifre da 0 a 9). Solitamente si indica con  $\Sigma$  o  $\Gamma$
- si definisce **stringa** come una sequenza finita di simboli (come per esempio una parola o una sequenza numerica). La stringa vuota è una sequenza di 0 simboli, e si indica con  $\varepsilon$  o  $\lambda$
- si definisce **lunghezza di una stringa** il numero di simboli che la compone (ovviamente contando ogni molteplicità). Se si ha  $w \in \Sigma^*$  è una stringa w con elementi da  $\Sigma^*$  (insieme di tutte le stringhe di tutte le lunghezze possibili fatte da  $\Sigma$ ), allora |w| è la lunghezza di w, inoltre  $|\varepsilon| = 0$ .

• si definisce **potenza di un alfabeto**  $\Sigma^k$  come l'insieme di tutte le sequenze (espressi come stringhe e non simboli) di lunghezza  $k \in \mathbb{N}, k > 0$  ottenibili da quell'alfabeto (se  $\Sigma^2$  si avranno tutte le sequenza di 2 elementi etc...). Se ho k=1 si ha  $\Sigma^1 \neq \Sigma$  in quanto ora ho stringhe e non simboli. Se ho k=0 ho  $\Sigma^0=\varepsilon$ . Dato k ho  $|\Sigma|$  che è la cardinalità dell'insieme  $\Sigma$  (e non la sua lunghezza come nel caso delle stringhe); sia  $w \in \Sigma^k = a_1, a_2, ..., a_k, a_i \in \Sigma$  e  $|\Sigma| = q$  ora:

$$|\Sigma^k| = q^k$$

• si definisce  $\Sigma^*$  come **chiusura di Kleene** che è l'unione infinita di  $\Sigma^k$  ovvero

$$\Sigma * = \Sigma^0 \cup \Sigma^1 \cup ... \cup \Sigma^k$$

• si ha che  $\Sigma^+$  è l'unione per  $k \geq 1$  di  $\Sigma^k$  ovvero:

$$\Sigma + = \Sigma^1 \cup \Sigma^2 \cup ... \cup \Sigma^k = \Sigma^* - \Sigma^0$$

per esempio, per l'insieme  $\{0,1\}$  si ha:

$$\Sigma^* = \{\varepsilon, 0, 1, 00, 01, 10, 100, 000, \ldots\}$$

 $\bullet$  quindi un **linguaggio** L è un insieme di stringhe e:

$$L\subseteq \Sigma^*$$

si hanno sottoinsiemi particolari, come l'insieme vuoto, che resta però un linguaggio, il **linguaggio vuoto** e  $\emptyset \in \Sigma^k$ ,  $|\emptyset| = 0$  che è diverso dal linguaggio che contiene la stringa vuota  $|\varepsilon| = 1$  (che conta come una stringa). Inoltre  $\Sigma^* \subseteq \Sigma^*$  che ha lunghezza infinita. Posso concatenare due stringhe con un punto:  $a \cdot b \cdot c = abc$  e  $a \cdot \varepsilon = a$ . Ovviamente la stringa concatenata è lunga come la somma delle lunghezze delle stringhe che la compongono. Vediamo qualche esempio di linguaggio:

-il linguaggio di tutte le stringhe che consistono in n0 seguiti da n 1:

$$\{\varepsilon, 01, 0011, 000111, \ldots\}$$

- l'insieme delle stringhe con un uguale numero di 0 e di 1:

$$\{\varepsilon, 01, 10.0011, 0101.1001, ..\}$$

- l'insieme dei numeri binari il cui valore è un numero primo:

$$\{\varepsilon, 10, 11, 101, 111, 1011, \ldots\}$$

- $-\Sigma^*$ è un linguaggio per ogni alfabeto  $\Sigma$
- Ø, il linguaggio vuoto, e $\{\varepsilon\}$ sono un linguaggio rispetto a qualunque alfabeto

Prendiamo un alfabeto  $\Sigma = \{0,1\}$  con la sua chiusura di Kleen  $\Sigma = \{0,1\}^*$ . Quando si ha un input si può avere un problema di decisione, P, che dia come output "si" o "no". Posso avere un problema di decisione (o membership) su  $w \in \Sigma = \{0,1\}^*$ , con w stringa, che dia in output "si" o "no". Un linguaggio L sarà:

$$L = \{w \in \{0,1\}^* \mid P(w) = si$$

quindi si ha che:

$$\Sigma^* \backslash L = \{ P(w) = no \}$$

Vediamo ora un esempio di *Context Free Language (CFL)*, costruito a partire da una *Context Free Grammar (CFG)*:

Esempio 1. Sia  $\Sigma = \{0,1\}$  e  $L_{pal} =$  "stringhe palindrome binarie". Quindi, per esempio,  $0110 \in L$ ,  $11011 \in L$  ma  $10010 \notin L$ . Si ha che  $\varepsilon$ , la stringa vuota, appartiene a L. Diamo una definizione ricorsiva:

- base:  $\varepsilon$ , 0 1  $\in L_{pal}$
- passo: se w è palindroma allora 0w0 è palindromo e 1w1 è palindromo

una variabile generica S può sottostare alle regole di produzione di una certa grammatica. In questo caso si ha uno dei seguenti:

$$S \to \varepsilon$$
,  $S \to 0$ ,  $S \to 1$ ,  $S \to 0S0$ ,  $S \to 1S1$ 

Si ha che una grammatica G è una quadrupla G = (V, T, P, S con:

- $\bullet$  V simboli variabili
- T simboli terminali, ovvero i simboli con cui si scrivono le stringhe alla fine
- $\bullet$  *P* regole di produzione
- S variabile di partenza start

riprendiamo l'esempio sopra:

#### Esempio 2.

$$G_{pal} = (V = \{S\}, T = \{0, 1\}, P, S)$$

con:

$$P = \{S \to \varepsilon, S \to 0, S \to 1, S \to 0S0, S \to 1S1\}$$

 $Si\ può\ ora\ costruire\ un\ algoritmo\ per\ creare\ una\ stringa\ palindroma\ a\ partire\ dalla\ grammatica\ G:$ 

$$\underbrace{S}_{start\;applico\;una\;regola} \xrightarrow{1S1 \to 01S10 \to \underbrace{01010}_{sostituisco\;variabile}}$$

con S, 1S1 e 01S10 che sono forme sentenziali. Posso così ottenere tutte le possibili stringhe. Esiste anche una forma abbreviata:

$$S \to \varepsilon |o| 1 |0S0| 1S1$$

Non si fanno sostituzioni in parallelo, prima una S e poi un'altra

Si hanno 4 grammatiche formali, qerarchia di Chomsky:

- **tipo 0:** non si hanno restrizioni sulle regole di produzione,  $\alpha \to \beta$ . Sono linguaggi ricorsivamente numerabili e sono rappresentati dalle *macchine di Turing*, deterministiche o non deterministiche (la macchina di Turing è un automa)
- **tipo 1:** il lato sinistro della produzione (*testo*) ha lunghezza uguale a quello destro (*corpo*). Sono grammatiche dipendenti dal contesto (*contestuali*) e come automa hanno *la macchina di Turing che lavora in spazio lineare*:

$$\alpha_1 A \alpha_2 \rightarrow \alpha_1 B \alpha_2$$

con  $\alpha_1$  e  $\alpha_2$  detti contesto e  $\alpha_1, \alpha_2, \beta \in (V \cup T)^*$ 

- tipo 2: sono quelle libere dal contesto, context free. Come regola ha  $A \to \beta$  con  $A \in V$  e  $\beta \in V \cup T$ )\* e come automa ha gli *automi a pila* non deterministici
- tipo 3: sono le grammatiche regolari. Come regole ha  $A \to \alpha B$  (o  $A \to B\alpha$ ) e  $A \to \alpha$  con  $A, B \in V$  e  $\alpha \in T$ . Come automi ha gli automi a stato finito deterministici o non deterministici

**Esempio 3.** Sia G = (V, T, O, E), con  $V = \{E, I\}$  e  $T = \{a, b, 0, 1, (,), +, *\}$  quindi ho le seguenti regole, è di tipo 3:

- 1.  $E \rightarrow I$
- 2.  $E \rightarrow E + E$
- 3.  $E \rightarrow E * E$
- 4.  $E \rightarrow (E)$
- 5.  $I \rightarrow a$
- 6.  $I \rightarrow b$
- 7.  $I \rightarrow Ia$
- 8.  $I \rightarrow Ib$
- 9.  $I \rightarrow I0$
- 10.  $I \rightarrow I1$

 $voglio\ ottenere\ a*(a+b00)\ sostituisco\ sempre\ a\ destra\ (right\ most\ derivation)$ 

$$E \to E * E \to E * (E) \to E * (E+E) \to E * (E+I) \to E + (E+I0)$$

$$\rightarrow R + (I + b00) \rightarrow E * (a + b00) \rightarrow I * (a + b00) \rightarrow a * (a + b00)$$

usiamo ora l'inferenza ricorsiva:

passo	stringa ricorsiva	var	prod	passo stringa impiegata
1	a	I	5	\
2	b	I	6	\
3	b0	I	9	2
4	b00	I	9	3
5	a	E	1	1
6	b00	E	1	4
7	a+b00	E	2	5,6
8	(a+b00)	E	4	7
9	a*(a+b00)	E	3	5, 8

definisco formalmente la derivazione  $\rightarrow$ :

**Definizione 1.** Prendo una grammatica G = (V, T, P, S), grammatica CFG. Se  $\alpha A\beta$  è una stringa tale che  $\alpha, \beta \in (V \cup T)^*$ , appartiene sia a variabili che terminali. Sia  $A \in V$  e sia  $a \to \gamma$  una produzione di G. Allora scriviamo:

$$\alpha A\beta \to \alpha \gamma \beta$$

 $con \ \gamma \in (V \cup T)^*$ .

Le sostituzioni si fanno indipendentemente da  $\alpha$  e  $\beta$ . Questa è quindi la definizione di derivazione.

**Definizione 2.** Definisco il simbolo  $\rightarrow +$ , ovvero il simbolo di derivazioni in 0 o più passi. Può essere definito in modo ricorsivo. Per induzione sul numero di passi.

- la base dice che  $\forall \alpha \in (V \cup T)^*, \ \alpha \to *\alpha$
- il passo è: se  $\alpha \to_G *\beta$  e  $\beta \to_G *\gamma$  allora  $\alpha \to *\gamma$

Si può anche dire che  $\alpha \to_G + \beta$  sse esiste una sequenza di stringhe  $\gamma_1, ..., \gamma_n$  con  $n \ge 1$  tale che  $\alpha = \gamma_1, \ \beta = \gamma_n$  e  $\forall i, 1 < i < n-1$  si ha che  $\gamma_1 \to \gamma_{i+1}$  la derivazione in 0 o più passi è la chiusura transitiva della derivazione

**Definizione 3.** avendo ora definito questi simboli possiamo definire una forma sentenziale. Infatti è una stringa  $\alpha$  tale che:

$$\forall \alpha \in (V \cup T)^* \ tale \ che \ S \rightarrow_G * \alpha$$

**Definizione 4.** data G = (V, T, P, S) si ha che  $L(G) = \{w \in T^* | S \to_G * w\}$  ovvero composto da stringhe terminali che sono derivabili o 0 o più passi.

Esempio 4. formare una grammatica CFG per il linguaggio:

$$L = \{0^n 1^n | n \ge 1\} = \{01, 0011, 000111, ...\}$$

con  $x^n$  intendo una concatenazione di n volte x (che nel nostro caso sono 0 e 1).

posso scrivere:

$$0^n 1^n = 00^{n-1} 1^{n-1} 1$$

il nostro caso base sarà la stringa 01, Poi si ha: G = /V, T, P, S),  $T = \{0, 1\}$ ,  $V = \{S\}$ , il caso base  $S \to 01$  e  $S \to 0S1$  il caso passo è quindi: se  $w = 0^{n-1}1^{n-1} \in L$  allora  $0w1 \in L$ .

Ora voglio dimostare che  $000111 \in L$ , ovvero  $S \to *000111$ :

$$S \rightarrow ~0S1 \rightarrow 00S11 \rightarrow 000S111$$

**Teorema 1.** data la grammatica  $G = \{V, T, P, S\}$  CFG e  $\alpha \in (V \cup T)^*$ . Si ha che vale  $S \to *\alpha$  sse  $S \to_{lm} *\alpha$  sse  $S \to_{rm} *\alpha$ . Con to<sub>lm</sub>\* simbolo di left most derivation e to<sub>rm</sub>\* simbolo di right most derivation

Esempio 5. formare una grammatica CFG per il linguaggio:

$$L = \{0^n 1^n | n \ge 0\} = \{\varepsilon, 01, 0011, 000111, \ldots\}$$

stavolta abbiamo anche la stringa vuota. Il caso base stavolta è  $S \to \varepsilon | \ 0S1$ 

**Esempio 6.** Fornisco una CFG per  $L = \{a^n | n \ge 1\} = \{a, aa, aaa, ...\}$ . La base è a

il passo è che se  $a^{n-1} \in L$  allora  $a^{n-1}a \in L$  ( o che  $aa^{n-1} \in L$ ). Si ha la grammatica  $G = \{V, T, P, S\}, V = \{S\}, T = \{a\}$  e si hanno  $S \to a \mid Sa$  (o  $S \to a \mid aS$ ). Dimostro che  $a^3 \in L$ .

$$S \rightarrow Sa \rightarrow Saa \rightarrow aaa$$

oppure

$$S \rightarrow aS \rightarrow aaS \rightarrow aaa$$

**Esempio 7.** trovo una CFG per  $L = \{(ab)^n | n \ge 1\} = \{ab, abab, ababab, ...\}$ La base è ab

il passo è che se  $(ab)^{n-1} \in L$  allora  $(ab)^{n-1}ab \in L$ .

Si ha la grammatica  $G = \{V, T, P, S\}$ ,  $V = \{S\}$ ,  $T = \{a, b\}$  (anche se in realtà  $T = \{ab\}$ ) e si hanno  $S \to ab$  | Aab. Poi dimostro come l'esempio sopra

**Esempio 8.** trovo una CFG per  $L = \{a^ncb^n|n \ge 1\} = acb$ , aacbb, aaacbbb, ...} Il caso base è acb il passo è che se  $a^{n-1}cb^{n-1} \in L$  allora  $a^{n-1}cb^{n-1}acb \in L$  Si ha la grammatica  $G = \{V, T, P, S\}$ ,  $V = \{S\}$ ,  $T = \{a, b, c\}$  e si hanno  $S \to aSb|acb$ .

 $dimostro\ che\ aaaacbbbbb \in L$ :

$$S \rightarrow aSb \rightarrow aaSbb \rightarrow aaaaSbbb \rightarrow aaaacbbbb$$

provo a usare anche una grammatica regolare, con le regole  $S \to aS|c,$   $c \to cB$  e  $B \to bB|b;$ 

$$S \rightarrow aS \rightarrow aaS \rightarrow aaC \rightarrow aacB \rightarrow aacb...$$

non si può dimostrare in quanto non si può imporre una regola adatta

**Esempio 9.**  $L = \{a^n c b^{n-1} | n \ge 2\}$ , con  $a^n c b^{n-1} = a^{n-1} a c b^{n-1}$ .  $S \to a S b | a a c b$ . Quindi:

$$S \to aSb \to aaaccbb \in L$$

**Esempio 10.** cerco CFG per  $L = \{a^n c^k b^n | n, k > 0\}$ . a e b devono essere uguali, uso quindi una grammatica context free, mentre c genera un linguaggio regolare.

Si ha la grammatica  $G = \{V, T, P, S\}, V = \{S, C\}, T = \{a, b, c\}$  e si hanno  $S \to aSb|aCb$  e  $C \to cC|c$ . dimostro che aaaccbbb  $\in L, n = 3, k = 2$ :

$$S \rightarrow aSb \rightarrow aaSbb \rightarrow aaaCbbb \rightarrow aaacCbbb \rightarrow aaaccbbb$$

Esempio 11. scrivere CFG per  $L = \{a^n b^n c^k b^k | n, k \ge 0\}$ 

$$= \{ w \in \{a, b, c, d\}^* | a^n b^n c^k b^k | n, k \ge 0 \}$$

quindi L concatena due linguaggi L1 e L2,  $X = \{a^nb^n\}$  e  $Y = \{c^kd^k\}$ :

$$X \to aXb|\varepsilon$$

$$Y \to cYd|\varepsilon$$

$$S \to XY$$

voglio derivare abcd:

$$S \to XY \to XcYd \to aXbcYd \to aXbc\varepsilon d \to a\varepsilon bc\varepsilon d \to abcd$$

voglio derivare cd

$$S \to XY \to Y \to cYd \to cd$$

Quindi se ho  $w \in L1, L2$ , ovvero appartenente ad una concatenazione di linguaggi prima uso le regole di un linguaggio, poi dell'altro e infine ottengo il risultato finale.

Esempio 12. scrivere CFG per  $L = \{a^n b^k c^k d^n | n > 0, k \ge 0\}$ .

$$S \to aSd \mid aXd$$

$$X \to bXc|\varepsilon$$

derivo aabcdd:

$$S \rightarrow aSd \rightarrow aaXdd \rightarrow aabXcdd \rightarrow aabcdd$$

Esempio 13. scrivere CFG per  $L = \{a^n c b^n c^m a d^m | n > 0, m \ge 1\}.$ 

$$S \to XY$$

$$X \to aXb|c$$

$$Y \rightarrow cUd|cad$$

$$S \to XY \to cY \to ccad$$

**Esempio 14.** scrivere CFG per  $L = \{a^{n+m}xc^nyd^m | n, m \ge 0\}$ .  $a^{n+m} = a^na^m \ o \ a^ma^n$ . Si hanno 2 casi:

1. 
$$L = \{a^n a^m x c^n y d^m | n, m \ge 0\}$$

2. 
$$L = \{a^m a^n x c^n y d^m | n, m \ge 0\}$$

ma solo  $L = \{a^m a^n x c^n y d^m | n, m \ge 0\}$  può generare una CFG (dove non si possono fare incroci, solo concatenazioni e inclusioni/innesti).

$$S \to aSd|Y$$

$$Y \to Xy$$

$$X \to aXc|x$$

si può fare in 2:

$$S \to aSd|Xy$$

$$X \to aXc|x$$

derivo con m = n = 1, aaxcyd:

$$S \rightarrow aSd \rightarrow aXyd \rightarrow aaXcyd \rightarrow aaxcyd$$

Esempio 15. scrivere CFG per  $L = \{a^n b^m | n \ge m \ge 0\}$ .

$$L = \{\varepsilon, a, ab, aa, aab, aabb, aaa, aaab, aaabb, aaabb, ...\}$$

Se  $n \ge m$  allora  $\exists k \ge 0 \rightarrow n = m + k$ . Quindi:

$$l = \{a^{m+k}b^m | m, k \ge 0\}$$

si può scrivere in 2 modi:

- 1.  $l = \{a^m a^k b^m | m, k \ge 0\}$  quindi con innesto
- 2.  $l = \{a^k a^m b^m | m, k \ge 0\}$  quindi con concatenazione

entrambi possibili per una CFG:

1.

$$S \to XY$$

 $X \to aX|\varepsilon$  si può anche scrivere  $X \to Xa|\varepsilon$ 

$$Y \to aYb|\varepsilon$$

oppure

$$S \to aS|X$$

$$X \to aXb|\varepsilon$$

2.

$$S \to aSb|\varepsilon$$
$$X \to aX|\varepsilon$$

**Esempio 16.** scrivere CFG per  $L = \{a^n b^{m+n} c^h | m > h \ge 0, n \ge 0\}$ . Se n > h allora  $\exists k \to n = h + k$ , quindi:

$$L = \{a^n b^{m+h+k} c^h | \, m > h \ge 0, \, n \ge 0 \}$$

. ovvero:

$$L = \{a^n b^n b^k b^h c^h | m \ge 0, k > 0, h \ge 0\}$$

si ha:

$$S \to XYZ$$

$$X \to aXb|\varepsilon$$

$$Y \to Yb|b$$

$$Z \to bZc|\varepsilon$$

si può anche fare:

$$S \to XY$$

$$X \to aXb|\varepsilon$$

$$Y \to bYc|Z$$

$$Z \to bZ|b$$

Esempio 17. scrivere CFG per  $L = \{a^nb^mc^k | k > n+m, n, m \ge 0\}$ . per n=m=0, k=1 avrò la stringa c. se k > n+m allora  $\exists l > 0 \rightarrow k = n+m+l$  quindi:

$$L = \{a^n b^m c^{n+m+l} | l > 0, n, m \ge 0\}$$

$$= L = \{a^n b^m c^n c^m c^l | l > 0, n, m \ge 0\}$$

sistem and o:

$$= L = \{a^n b^m c^l c^m cnl | \, l > 0, \, n, m \geq 0 \}$$

quindi:

$$S \to aSc|X$$

$$X \to bXc|Y$$

$$Y \to cY|c$$

Esempio 18. scrivere CFG per  $L = \{a^nxc^{n+m}y^hz^kd^{m+h}| n, m, k, h \ge 0\}$ . ovvero:

$$L = \{a^n x c^n c^m y^h z^k d^h d^m | n, m, k, h > 0\}$$

quindi avrò:

$$S \to XY$$

$$X \to aXc|x$$

$$Y \to cYd|W$$

$$W \to yWd|X$$

$$Z \to zZ|\varepsilon$$

Esempio 19. vediamo un esempio di grammatica dipendente dal contesto:

$$L = \{a^n b^n c^n | n \ge 1\}$$

 $G = \{V, T, P, S\} = \{(S, B, C, X)\} = \{(a, b, c), P, S\}$  ecco le regole di produzione (qui posso scambiare variabili a differenza delle context free):

- 1.  $S \rightarrow aSBC$
- 2.  $S \rightarrow aBC$
- 3.  $CB \rightarrow XB$
- 4.  $XB \rightarrow XC$
- 5.  $XC \rightarrow BC$
- 6.  $aB \rightarrow ab$
- 7.  $bB \rightarrow bb$
- 8.  $bC \rightarrow bc$
- 9.  $cC \rightarrow cc$

vediamo un esempio di derivazione: per n = 1 ho abc ovvero:

$$S \to aBC \to abC \to abc$$

 $con\ n=2\ ho\ aabbcc\colon S \to aSBC \to aaBCBC \to aaBXBC \to aaBXCC \to aabBCC \to aabBCC \to aabbcC \to aabbcC \to aabbcC$